✅ Lösung — Statistik als Fundament

Kapitel 1 · Musterlösung mit vollständigem Rechenweg

> Für Dozierende / Selbstkontrolle. Rundungen: 2–3 Nachkommastellen; kleine Abweichungen durch Rundung sind bei Studierenden zu akzeptieren.

Aufgabe 1 — Lagemaße & Streuung

Daten: $0, 1, 1, 2, 2, 2, 3, 5$ ($n = 8$, bereits sortiert)

a) Lagemaße

- $\bar{x} = \frac{0+1+1+2+2+2+3+5}{8} = \frac{16}{8} = 2$
- Median: $n = 8$ (gerade) → Mittel der 4. und 5. sortierten Werte: $\frac{2+2}{2} = 2$
- Modus: 2 (kommt 3× vor, häufigster Wert)

b) Welches Lagemaß passt am besten?

Mittelwert, Median und Modus sind hier zufällig identisch ($= 2$) — ungewöhnlich, aber an diesem kleinen, moderat rechtsschiefen Datensatz (Ausreißer bei 5) so möglich. In der Praxis wäre bei stärkerer Schiefe der **Median** robuster, da er von dem Ausreißerwert 5 nicht verzerrt wird (der Mittelwert würde bei stärkerer Rechtsschiefe nach oben gezogen). Lehrpunkt: Studierende sollen erkennen, *warum* der Median hier robust ist, nicht nur den Wert nennen.

c) Stichprobenvarianz & Standardabweichung

Abweichungen vom Mittelwert (2): $-2, -1, -1, 0, 0, 0, 1, 3$ Quadrierte Abweichungen: $4, 1, 1, 0, 0, 0, 1, 9$ → Summe $= 16$

$$s^2 = \frac{16}{n-1} = \frac{16}{7} \approx 2{,}29 \quad \Rightarrow \quad s = \sqrt{2{,}29} \approx 1{,}51$$

d) Interpretation

"Im Schnitt melden unsere Versicherten etwa 2 Schäden pro Jahr, mit einer typischen Schwankung von rund 1,5 Schäden nach oben oder unten — die meisten liegen also zwischen 0,5 und 3,5 Schäden."

Aufgabe 2 — Kovarianz & Korrelation

Fahrzeug	x	y	$x - \bar{x}$	$y - \bar{y}$	$(x-\bar{x})(y-\bar{y})$
A	2	620	−4	−580	2.320
B	4	850	−2	−350	700
C	6	1.300	0	100	0
D	8	1.400	2	200	400
E	10	1.830	4	630	2.520

a) $\bar{x} = \frac{30}{5} = 6, \bar{y} = \frac{6.000}{5} = 1.200$

b) Summe der Produkte $= 2.320 + 700 + 0 + 400 + 2.520 = 5.940$

c) Kovarianz

$$\mathrm{Cov}(x,y) = \frac{5.940}{n-1} = \frac{5.940}{4} = 1.485 \text{ EUR·Jahre}$$

d) Varianzen und Korrelationskoeffizient

Quadrierte Abweichungen: x: $16, 4, 0, 4, 16$ → Summe $= 40$; y: $336.400, 122.500, 10.000, 40.000, 396.900$ → Summe $= 905.800$

$$s_x^2 = \frac{40}{4} = 10 \;\Rightarrow\; s_x \approx 3{,}16 \qquad s_y^2 = \frac{905.800}{4} = 226.450 \;\Rightarrow\; s_y \approx 475{,}87$$

$$r = \frac{\mathrm{Cov}(x,y)}{s_x \cdot s_y} = \frac{1.485}{3{,}16 \times 475{,}87} \approx \frac{1.485}{1.505{,}0} \approx 0{,}987$$

e) Interpretation

$r \approx 0{,}99$: ein sehr starker, **positiver** linearer Zusammenhang — ältere Fahrzeuge haben tendenziell höhere Reparaturkosten. Kausalität ist **nicht** belegt; Korrelation zeigt nur den statistischen Zusammenhang (denkbare Drittvariablen: Kilometerstand, Ersatzteilpreise für ältere Modelle).

Aufgabe 3 — z-Transformation

a) z-Werte ($z_i = \frac{y_i - 1.200}{475{,}87}$, mit s_y aus Aufgabe 2d)

Fahrzeug	y	$y - \bar{y}$	z
A	620	−580	−1,219
B	850	−350	−0,735
C	1.300	+100	+0,210
D	1.400	+200	+0,420
E	1.830	+630	+1,324

b) Fahrzeug E hat mit $z \approx +1{,}32$ den auffälligsten Wert — seine Reparaturkosten liegen mehr als eine Standardabweichung über dem Durchschnitt, deutlich der teuerste Fall relativ zur Gesamtverteilung.

c) Kontrollfrage

Die Summe aller z-Werte muss (näherungsweise) **0** ergeben, da z um den Mittelwert zentriert ist: $-1{,}219 - 0{,}735 + 0{,}210 + 0{,}420 + 1{,}324 \approx 0{,}000$ ✓ (kleine Abweichung nur durch Rundung).

Aufgabe 4 — Lineare Regression von Hand

a) Steigung & Achsenabschnitt

$$b = \frac{\mathrm{Cov}(x, y)}{s_x^2} = \frac{1.485}{10} = 148{,}5$$

$$a = \bar{y} - b\bar{x} = 1.200 - 148{,}5 \cdot 6 = 1.200 - 891 = 309$$

b) Regressionsgerade

$$\hat{y} = 309 + 148{,}5 \cdot x$$

c) Vorhersage für $x = 12$

$$\hat{y} = 309 + 148{,}5 \cdot 12 = 309 + 1.782 = 2.091 \text{ EUR}$$

Der beobachtete Datenbereich reicht nur bis $x = 10$ — bei $x = 12$ **extrapoliert** das Modell außerhalb der Trainingsdaten. Die Vorhersage ist plausibel, aber weniger sicher als eine Interpolation innerhalb $[2, 10]$; Studierende sollten diesen Vorbehalt benennen.

d) R^2

Vorhergesagte Werte, Residuen und quadrierte Residuen je Fahrzeug:

x	y (echt)	$\hat{y}$ (Modell)	$y - \hat{y}$	$(y - \hat{y})^2$
2	620	606	+14	196
4	850	903	−53	2.809
6	1.300	1.200	+100	10.000
8	1.400	1.497	−97	9.409
10	1.830	1.794	+36	1.296

$$SS_{\text{res}} = \sum (y - \hat{y})^2 = 196 + 2.809 + 10.000 + 9.409 + 1.296 = 23.710$$

SS_{tot} ist die Summe der quadrierten Abweichungen vom Mittelwert $\bar{y}$ — dieselbe Zahl, die in Aufgabe 2d als Zwischenschritt für s_y^2 berechnet wurde:

$$SS_{\text{tot}} = 905.800$$

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{23.710}{905.800} \approx 1 - 0{,}0262 \approx 0{,}974$$

Interpretation für den Fachbereich: "Etwa 97 % der Schwankungen in den Reparaturkosten lassen sich allein durch das Fahrzeugalter erklären — ein sehr starkes Modell für nur eine erklärende Variable."

> Kontrolle: Für die einfache lineare Regression mit nur einer erklärenden Variable stimmt R^2 rechnerisch mit r^2 überein: $0{,}987^2 \approx 0{,}974$ ✓ — beide Wege führen zum selben Ergebnis.

Aufgabe 5 — Logistische Regression & Odds Ratio

$z = -2{,}1 + 0{,}55x_1 + 0{,}9x_2$

a) Tagsüber ($x_1 = 3, x_2 = 0$)

$$z = -2{,}1 + 0{,}55 \cdot 3 + 0{,}9 \cdot 0 = -2{,}1 + 1{,}65 = -0{,}45$$

$$\hat{p} = \frac{1}{1 + e^{0{,}45}} = \frac{1}{1 + 1{,}568} \approx 0{,}389 \ (38{,}9\%)$$

b) Nachts ($x_1 = 3, x_2 = 1$)

$$z = -2{,}1 + 1{,}65 + 0{,}9 = 0{,}45$$

$$\hat{p} = \frac{1}{1 + e^{-0{,}45}} = \frac{1}{1 + 0{,}638} \approx 0{,}610 \ (61{,}0\%)$$

c) Odds & Odds Ratio

- Odds (tags) $= \dfrac{0{,}389}{1 - 0{,}389} = \dfrac{0{,}389}{0{,}611} \approx 0{,}637$
- Odds (nachts) $= \dfrac{0{,}610}{0{,}390} \approx 1{,}564$
- Odds Ratio $= \dfrac{1{,}564}{0{,}637} \approx 2{,}456$

d) Vergleich mit e^{β_2}

$$e^{0{,}9} \approx 2{,}460$$

Die beiden Werte stimmen (bis auf Rundung) überein — das bestätigt die Kerneigenschaft der logistischen Regression: e^{β_j} liefert die Odds Ratio für Merkmal j **direkt aus dem Koeffizienten**, ohne dass man zwei konkrete Fälle durchrechnen muss. Genau das macht die Koeffizienten interpretierbar.

Aufgabe 6 (Bonus) — Signifikanz in der Praxis

a) Entscheidungen bei $\alpha = 0{,}05$

1. $p = 0{,}002 < 0{,}05$ → H_0 **verwerfen** (Effekt signifikant)
2. $p = 0{,}21 \geq 0{,}05$ → H_0 **beibehalten** (kein ausreichender Beweis für einen Effekt)
3. $p = 0{,}03 < 0{,}05$ → formal H_0 **verwerfen** — aber siehe b)

b) Was läuft in Fall 3 schief?

Bei sehr großen Stichproben (hier 850.000 Verträge) werden selbst **winzige, praktisch irrelevante Effekte** statistisch signifikant, weil der Standardfehler mit wachsendem n sinkt. Ein Effekt von 1,20 EUR ist für keine reale Entscheidung (Tarifierung, Rückstellungen) handlungsrelevant — trotz $p < \alpha$. Das ist der klassische Unterschied zwischen **statistischer Signifikanz** (ist der Effekt von Null unterscheidbar?) und **praktischer/ökonomischer Relevanz** (ist der Effekt groß genug, um etwas zu ändern?).

c) Empfehlung an den Fachbereich

Nein — man sollte sich nicht allein auf p-Werte verlassen. Immer zusammen berichten: Effektgröße (wie groß, in EUR/Prozentpunkten?), Konfidenzintervall, Stichprobengröße und fachliche Plausibilität. Ein p-Wert beantwortet nur "ist da überhaupt etwas?", nicht "ist es wichtig genug, um zu handeln?".