💻 Übung — Statistik als Fundament

Kapitel 1 · Dauer: 30–60 Min · Von Hand oder mit Python — Deine Wahl

Ausgangslage

Du arbeitest als Analyst:in bei einem Kfz-Versicherer. Bevor Dein Team Machine-Learning-Modelle auf hunderttausende Verträge loslässt, sollst Du an zwei kleinen Beispieldatensätzen zeigen, dass Du die statistischen Grundlagen dahinter verstehst.

Empfohlen: Rechne mindestens die erste Aufgabe von Hand (Taschenrechner reicht) — das schärft das Verständnis für das, was später Python automatisiert. Ab dann steht es Dir frei, mit Python (z. B. NumPy/SciPy) nachzurechnen und Deine Handrechnung zu verifizieren.

Bearbeite die Aufgaben in der angegebenen Reihenfolge. Aufgabe 5 ist ein Bonus, falls Zeit bleibt.

Aufgabe 1 — Lagemaße & Streuung (≈10 Min)

Ein Team hat die **Anzahl gemeldeter Schäden im letzten Jahr** von 8 zufällig ausgewählten Versicherten erfasst:

$$0,\ 1,\ 1,\ 2,\ 2,\ 2,\ 3,\ 5$$

a) Berechne das arithmetische Mittel, den Median und den Modus.

b) Welches Lagemaß beschreibt die "typische" Schadenhäufigkeit hier am besten? Begründe kurz — beachte den Wert 5 am rechten Rand der Verteilung.

c) Berechne die Stichprobenvarianz $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$ und die Standardabweichung s.

d) Was bedeutet die Standardabweichung hier inhaltlich, in einem Satz an einen Fachbereichsleiter ohne Statistik-Hintergrund formuliert?

Aufgabe 2 — Kovarianz & Korrelation (≈10 Min)

Für 5 Fahrzeuge liegen Alter (in Jahren) und die zuletzt abgerechneten Reparaturkosten (in EUR) vor:

Fahrzeug	Alter x (Jahre)	Reparaturkosten y (EUR)
A	2	620
B	4	850
C	6	1.300
D	8	1.400
E	10	1.830

a) Berechne $\bar{x}$ und $\bar{y}$.

b) Stelle eine Tabelle mit den Abweichungen $(x_i - \bar{x})$, $(y_i - \bar{y})$ und ihrem Produkt auf. Summiere die Produkte — das ist der Zähler der Kovarianz-Formel.

c) Berechne die Kovarianz $\mathrm{Cov}(x,y) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$.

d) Berechne zusätzlich die Stichprobenvarianzen s_x^2 und s_y^2 (gleiche Formel wie in Aufgabe 1c, einmal für x, einmal für y), und daraus den Pearson-Korrelationskoeffizienten $r = \frac{\mathrm{Cov}(x,y)}{s_x \cdot s_y}$.

e) Interpretiere r: Richtung und Stärke des Zusammenhangs. Ist Kausalität belegt?

> Behalte $\mathrm{Cov}(x,y)$ und s_x^2 — Du brauchst beide in Aufgabe 4 wieder.

Aufgabe 3 — z-Transformation (≈8 Min)

Nutze weiterhin den Datensatz aus Aufgabe 2 (Reparaturkosten y) und die Standardabweichung s_y, die Du dort in Teilaufgabe d) berechnet hast.

a) Standardisiere jeden der 5 Reparaturkosten-Werte mit $z_i = \frac{y_i - \bar{y}}{s_y}$.

b) Welches Fahrzeug hat den auffälligsten (am weitesten von 0 entfernten) z-Wert? Was sagt das über diesen Fall aus?

c) Kontrollfrage: Was sollte die Summe aller z-Werte (näherungsweise) ergeben? Prüfe das an Deinem Ergebnis.

Aufgabe 4 — Lineare Regression von Hand (≈15 Min)

Weiter mit dem Datensatz und den Zwischenergebnissen aus Aufgabe 2.

a) Berechne die Steigung $b = \frac{\mathrm{Cov}(x,y)}{s_x^2}$ und den Achsenabschnitt $a = \bar{y} - b\bar{x}$ (Methode der kleinsten Quadrate, OLS).

b) Formuliere die Gleichung der Regressionsgeraden $\hat{y} = a + bx$.

c) Ein sechstes Fahrzeug ist 12 Jahre alt. Sage die erwarteten Reparaturkosten voraus. Bewegt sich diese Vorhersage noch innerhalb des beobachteten Datenbereichs, oder handelt es sich um eine Extrapolation?

d) Bestimme für jedes der 5 Fahrzeuge den vorhergesagten Wert $\hat{y}$ und das Residuum $(y - \hat{y})$, und summiere die quadrierten Residuen zu $SS_{\text{res}} = \sum (y - \hat{y})^2$. SS_{tot} hast Du bereits in Aufgabe 2b berechnet — es ist die Summe der quadrierten Abweichungen von $\bar{y}$. Berechne daraus $R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$ und interpretiere den Wert für einen Fachbereich, der nicht weiß, was R^2 ist.

Aufgabe 5 — Logistische Regression & Odds Ratio (≈10 Min)

Das Data-Science-Team hat bereits ein Betrugsmodell trainiert (die Koeffizienten sind gegeben, Du musst sie **nicht** selbst schätzen):

$$z = -2{,}1 + 0{,}55 \cdot x_1 + 0{,}9 \cdot x_2$$

wobei x_1 = Anzahl Vorschäden, x_2 = Schadenmeldung nachts eingegangen (1 = ja, 0 = nein).

a) Berechne $\hat{p}$ für einen Kunden mit 3 Vorschäden, der **tagsüber** meldet ($x_2 = 0$), mit der Sigmoid-Funktion $\hat{p} = \frac{1}{1 + e^{-z}}$.

b) Berechne $\hat{p}$ für denselben Kunden, wenn er stattdessen **nachts** meldet ($x_2 = 1$).

c) Berechne für beide Fälle die Odds ($\frac{\hat{p}}{1-\hat{p}}$) und das Verhältnis der beiden Odds zueinander (Odds Ratio).

d) Vergleiche Dein Ergebnis aus c) mit $e^{\beta_2} = e^{0{,}9}$. Stimmen die Werte überein? Was sagt das über die Interpretierbarkeit von Odds Ratios aus?

Aufgabe 6 (Bonus) — Signifikanz in der Praxis (≈10 Min)

Drei Kolleg:innen präsentieren Dir ihre Ergebnisse. $\alpha = 0{,}05$ ist die vereinbarte Schwelle.

1. *"Fahrzeugalter beeinflusst die Reparaturkosten, $p = 0{,}002$."*
2. *"Die Farbe des Fahrzeugs beeinflusst die Schadenhäufigkeit, $p = 0{,}21$."*
3. *"Bei 850.000 Verträgen beeinflusst das Geburtsdatum (Wochentag) die Schadenhöhe minimal, aber signifikant, $p = 0{,}03$. Der Effekt liegt bei 1,20 EUR."*

a) Triff für jede Aussage die Entscheidung: H_0 verwerfen oder beibehalten?

b) Fall 3 ist ein Sonderfall. Was läuft hier schief, obwohl der p-Wert unter α liegt? (Stichwort: Effektgröße vs. statistische Signifikanz, Stichprobengröße)

c) Was würdest Du dem Fachbereich empfehlen: Soll man sich bei Entscheidungen allein auf p-Werte verlassen? Begründe in 2–3 Sätzen.