✅ Lösung — Betrugserkennung klassifizieren

Session 4 · Musterlösung mit vollständigem Rechenweg

> Für Dozierende / Selbstkontrolle. Rundungen: 2–3 Nachkommastellen; kleine Abweichungen durch Rundung sind bei Studierenden zu akzeptieren.

Aufgabe 1 — Confusion Matrix & Metriken von Hand

a) Confusion Matrix

Auszählen der 20 Fälle:

	Modell: Betrug	**Modell: Kein Betrug**
Wirklich: Betrug	TP = 5 (Fälle 1, 7, 10, 15, 18)	FN = 2 (Fälle 4, 13)
Wirklich: Kein Betrug	FP = 4 (Fälle 5, 9, 14, 19)	TN = 9 (Fälle 2, 3, 6, 8, 11, 12, 16, 17, 20)

Konsistenzcheck: $5 + 2 + 4 + 9 = 20$ ✓

b) Metriken

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{5 + 9}{20} = \frac{14}{20} = 0{,}70 = 70{,}0$$

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{5}{9} \approx 0{,}556 = 55{,}6$$

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{5}{7} \approx 0{,}714 = 71{,}4$$

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R} = 2 \cdot \frac{0{,}556 \times 0{,}714}{0{,}556 + 0{,}714} \approx 0{,}625 = 62{,}5$$

c) Einordnung für die Geschäftsleitung

70 % Accuracy klingt solide, verdeckt aber zwei unterschiedliche Schwächen: Von den 9 Fällen, die das Modell als "Betrug" markiert, sind nur 5 (55,6 %) wirklich Betrug — **fast jeder zweite Alarm ist ein Fehlalarm**. Und von den 7 tatsächlichen Betrugsfällen erkennt das Modell nur 5 (71,4 %) — **gut jeder vierte Betrugsfall bleibt unentdeckt**. Die Geschäftsleitung übersieht, dass Accuracy beide Fehlerarten (Fehlalarm vs. übersehener Betrug) zu einer Zahl verdichtet, obwohl sie geschäftlich sehr unterschiedliche Kosten verursachen (siehe Aufgabe 3).

Aufgabe 2 — KNN von Hand

a) Euklidische Distanzen zum neuen Fall (14, 7)

Fall	x	y	$(14-x)^2$	$(7-y)^2$	Summe	d	Label
H1	2	1	144	36	180	13,416	Legitim
H2	3	2	121	25	146	12,083	Legitim
H3	15	8	1	1	2	1,414	Betrug
H4	4	1	100	36	136	11,662	Legitim
H5	18	9	16	4	20	4,472	Betrug
H6	6	3	64	16	80	8,944	Legitim
H7	16	7	4	0	4	2,000	Betrug
H8	5	2	81	25	106	10,296	Legitim
H9	17	10	9	9	18	4,243	Betrug
H10	3	1	121	36	157	12,530	Legitim

b) Sortiert nach Distanz (aufsteigend)

1. H3 (1,414, Betrug)
2. H7 (2,000, Betrug)
3. H9 (4,243, Betrug)
4. H5 (4,472, Betrug)
5. H6 (8,944, Legitim)
6. H8 (10,296, Legitim)
7. H4 (11,662, Legitim)
8. H2 (12,083, Legitim)
9. H10 (12,530, Legitim)
10. H1 (13,416, Legitim)

Die **5 nächsten Nachbarn** (K = 5): H3, H7, H9, H5, H6.

c) Majority Voting (K = 5)

4 von 5 Nachbarn (H3, H7, H9, H5) sind "Betrug", nur 1 (H6) ist "Legitim" → Modell klassifiziert den neuen Fall als **Betrug**.

d) K = 3 vs. K = 9

- **K = 3:** nächste drei Nachbarn sind H3, H7, H9 — alle "Betrug" → 3/3 → **Betrug**. Gleiches Ergebnis wie bei K = 5, sogar eindeutiger.
- **K = 9:** alle Fälle außer dem am weitesten entfernten H1 fließen ein. Davon sind H3, H7, H9, H5 "Betrug" (4) und H6, H8, H4, H2, H10 "Legitim" (5) → Mehrheit **Legitim** — die Klassifikation **kippt**!

Lehrpunkt: Die Wahl von K ist keine Nebensächlichkeit. Ein zu kleines K (hier K = 3) folgt nur dem unmittelbaren lokalen Muster (hier eindeutig, aber bei verrauschten Daten anfällig für

Ausreißer). Ein zu großes K (hier K = 9) zieht weit entfernte, weniger relevante Nachbarn hinzu und kann die Entscheidung "verwässern" bzw. sogar umkehren — hier, weil die 10 historischen Fälle stark in zwei Cluster (kleine/junge vs. große/alte Schäden) zerfallen und K = 9 praktisch fast den gesamten Datensatz einbezieht, statt nur die wirklich ähnlichen Nachbarn.

Aufgabe 3 — Business-Entscheidung: Recall vs. Precision

a) Recall & Precision

Modell A: $\text{Recall} = \frac{6}{10} = 60, \text{Precision} = \frac{6}{14} \approx 42{,}9$

Modell B: $\text{Recall} = \frac{9}{10} = 90, \text{Precision} = \frac{9}{49} \approx 18{,}4$

b) Gesamtschaden

Modell A: $4 \times 15.000 + 8 \times 500 = 60.000 + 4.000 = \text{EUR } 64.000$

Modell B: $1 \times 15.000 + 40 \times 500 = 15.000 + 20.000 = \text{EUR } 35.000$

c) Empfehlung

Trotz der deutlich niedrigeren Precision (18,4 % vs. 42,9 %) verursacht **Modell B den geringeren Gesamtschaden** (EUR 35.000 vs. EUR 64.000), weil unerkannter Betrug (EUR 15.000) 30× teurer ist als ein Falschalarm (EUR 500). Die vielen zusätzlichen Fehlalarme von Modell B (40 statt 8) fallen finanziell kaum ins Gewicht gegen den einen zusätzlichen übersehenen Betrugsfall, den sich Modell A leistet. Empfehlung: **Modell B**, sofern die Fehlalarme organisatorisch (Kapazität für Nachprüfungen) verkraftbar sind.

d) Sensitivität bei höheren Falschalarm-Kosten (EUR 2.000 statt EUR 500)

Modell A: $4 \times 15.000 + 8 \times 2.000 = 60.000 + 16.000 = \text{EUR } 76.000$

Modell B: $1 \times 15.000 + 40 \times 2.000 = 15.000 + 80.000 = \text{EUR } 95.000$

Die Empfehlung **kippt**: Jetzt ist **Modell A** günstiger (EUR 76.000 vs. EUR 95.000), weil die vielen Fehlalarme von Modell B bei gestiegenen Fehlalarmkosten stärker ins Gewicht fallen als der eine zusätzliche unerkannte Betrugsfall. **Lehrpunkt:** Die "richtige" Precision/Recall-Balance ist keine feste Eigenschaft eines Modells, sondern hängt vollständig von den aktuellen Kostenannahmen ab — ändern sich die Kosten, ändert sich die optimale Wahl.

Aufgabe 4 (Bonus) — Welcher Algorithmus passt?

1. **Random Forest** — große tabellarische Datenmenge, schnelle robuste Baseline ohne aufwendiges Hyperparameter-Tuning ist wichtiger als die letzten Prozentpunkte Accuracy.
2. **Gradient Boosting (XGBoost)** — Accuracy-Fokus, Rechenzeit ist kein Hindernis, Validation Set zur Überwachung des Overfitting-Risikos ist vorhanden — genau das Szenario, für das Boosting seinen Mehraufwand rechtfertigt.
3. **k-Nearest Neighbors (KNN)** — kleines, strukturiertes Feature-Set, kein Trainingsaufwand nötig (Lazy Learning), für eine überschaubare Fallzahl (50 Großschäden) gut geeignet.
4. **Convolutional Neural Network (CNN)** — Bilddaten (Schadensfotos) erfordern ein Verfahren, das räumliche Muster erkennt; kommt in Kapitel 6 (Deep Learning).

5. **Natural Language Processing (NLP)** — Freitext erfordert Sprachverarbeitung (Tokenisierung, Semantik); kommt in Kapitel 7.